

ISW - 132 - 1

Apache Hadoop y Apache Spark

Herramientas para el análisis de datos a gran escala

INTEGRANTES

Kayli D. Liriano Castillo — 2023-3539

Fitzroy J. Whyte Zabala — 2023-3959


Cesar L. Rijo Cedano — 2023-3478

Introducción

Las organizaciones generan enormes cantidades de información a través de aplicaciones, redes sociales, sistemas empresariales, sensores, páginas web y dispositivos móviles. Cuando ese volumen supera lo que un programa tradicional puede procesar, entramos al terreno del Big Data.

Hadoop y Spark

Ambas herramientas permiten trabajar con datos distribuidos en varias computadoras. Hadoop se centra en el almacenamiento y el procesamiento por lotes; Spark ofrece un motor más flexible para análisis, consultas y aprendizaje automático.



¿Qué es Apache Hadoop?

Framework de código abierto diseñado para almacenar y procesar grandes cantidades de datos de manera distribuida.



Distribución

En lugar de usar una sola computadora, divide los datos y el trabajo entre varias máquinas de un clúster.



Escala masiva


Permite trabajar con conjuntos de datos que ocupan gigabytes, terabytes o incluso petabytes.



Tolerancia a fallos


Si una máquina del clúster falla, el sistema sigue funcionando gracias a las copias de los datos.

Componentes principales




HDFS

Hadoop Distributed File System. Almacena archivos grandes divididos en bloques, distribuidos entre DataNodes y administrados por un NameNode.




MapReduce

Modelo de procesamiento en dos etapas — Map divide y procesa; Reduce agrupa y combina los resultados obtenidos.



YARN

Yet Another Resource Negotiator. Administra memoria y capacidad de procesamiento, y decide cuándo se ejecuta cada tarea.



Hadoop Common

Conjunto de librerías y utilidades compartidas que permiten funcionar a los demás componentes del ecosistema.

¿Cómo funciona el proceso completo?



Hadoop está diseñado para ser tolerante a fallos: los bloques replicados en distintos DataNodes permiten continuar trabajando aunque una máquina del clúster deje de funcionar.

Ventajas y desventajas

VENTAJAS

- Almacena cantidades muy grandes de datos
- Escalable: se agregan más computadoras al clúster
- Tolerante a fallos
- Software de código abierto
- Admite datos estructurados y no estructurados
- Utiliza hardware relativamente económico

DESVENTAJAS

- Instalación y configuración complejas
- MapReduce puede ser lento (uso constante de disco)
- No es ideal para análisis en tiempo real
- Requiere conocimientos de sistemas distribuidos
- Ineficiente con muchos archivos pequeños

Aplicaciones típicas

1

Almacenar registros de servidores

2

Analizar datos históricos

3

Procesar información de redes sociales

4

Detectar patrones en transacciones

5

Crear repositorios o lagos de datos

6

Analizar navegación web

7

Procesar datos de sensores

¿Qué es Apache Spark?

Motor de procesamiento y análisis de datos a gran escala, capaz de ejecutarse en una sola computadora o en un clúster de varias máquinas.



Multilenguaje

Se desarrolla con Python (PySpark), Java, Scala y R.



En memoria


Mantiene datos temporalmente en memoria, reduciendo lecturas y escrituras en disco.



Versátil


Se usa en ingeniería de datos, ciencia de datos y aprendizaje automático.

Componentes principales




Spark Core

Núcleo del sistema: distribuye tareas, administra memoria y recupera trabajos tras fallos.




Spark SQL

Procesa datos estructurados mediante consultas SQL y DataFrames.




Structured Streaming

Procesa flujos de datos que llegan de forma continua, casi en tiempo real.



MLlib

Biblioteca de aprendizaje automático: clasificación, regresión, agrupamiento y más.



GraphX

Procesamiento de grafos para analizar relaciones, rutas y redes de conexión.

Conceptos clave de Spark

● RDD

Resilient Distributed Dataset — colección de datos distribuida que admite transformaciones en paralelo y recuperación ante fallos. Sigue siendo la base conceptual, aunque hoy se recomienda usar DataFrames para datos estructurados.

● DataFrame

Colección distribuida de datos organizada en columnas con nombre, similar a una tabla SQL. Permite seleccionar, filtrar, agrupar, ordenar y combinar información.

Transformaciones vs. Acciones

Evaluación perezosa (lazy evaluation): las transformaciones se planifican, y solo al ejecutar una acción se procesan realmente.

TRANSFORMACIONES

`select() · filter()`
`groupBy() · orderBy()`

ACCIONES

`show() · count()`
`collect() · write()`

Ejemplo: $2 \text{ laptops} \times 45,000 = 90,000$ (nueva columna calculada con una transformación)

Arquitectura básica de una aplicación Spark

1

Driver

Ejecuta el programa principal y organiza las tareas.

2

Cluster Manager

Administra los recursos disponibles del clúster.

3

Executors

Procesan las tareas y almacenan datos temporalmente.

4

Tasks

Pequeñas unidades de trabajo enviadas a los Executors.

En una ejecución local, una sola computadora representa estos cuatro elementos; en un entorno empresarial, las tareas se distribuyen entre varias máquinas del clúster.

Ventajas y desventajas

VENTAJAS

- Procesamiento distribuido y en memoria
- Apropiado para análisis interactivo
- SQL, aprendizaje automático y flujos de datos
- APIs para varios lenguajes
- Lee CSV, JSON, Parquet y más
- Puede trabajar junto con Hadoop y HDFS

DESVENTAJAS

- Puede consumir mucha memoria
- Configuración de clúster compleja
- Requiere optimizar particiones y recursos
- Poca ventaja en datasets muy pequeños
- Movimientos costosos de datos entre máquinas

Aplicaciones típicas

1

Analizar ventas

2

Detectar operaciones
sospechosas

3

Procesar registros de
aplicaciones

4

Crear sistemas de
recomendación

5

Preparar datos para modelos
de IA

6

Analizar información de
clientes

7

Procesar datos continuos

8


Ejecutar consultas sobre
grandes datasets

Hadoop vs. Spark

Aspecto	Hadoop	Spark
Tipo principal	Almacenamiento y procesamiento	Motor de procesamiento y análisis
Almacenamiento	HDFS	No posee sistema propio
Procesamiento	MapReduce	DataFrames, SQL, RDD y más
Uso de memoria	Principalmente disco	Puede mantener datos en memoria
Velocidad	Procesamiento por lotes	Análisis iterativos e interactivos
Tiempo real	Limitado	Structured Streaming
Aprendizaje automático	Herramientas adicionales	Incluye MLlib

Hadoop y Spark trabajando juntos

En un ambiente empresarial, ambas tecnologías suelen complementarse: Hadoop almacena la información y Spark se encarga de analizarla.



HDFS almacena los datos • **YARN** administra los recursos del clúster • **Spark** procesa y analiza la información

Conclusión

Apache Hadoop aporta HDFS, MapReduce y YARN para almacenar información de forma distribuida, administrar recursos y procesar datos en paralelo. Apache Spark se especializa en el análisis: sus DataFrames, Spark SQL, Structured Streaming y MLlib permiten resolver problemas de ventas, aprendizaje automático y procesamiento de eventos en tiempo casi real.

IDEA CLAVE

*No compiten entre sí: se complementan.
Hadoop almacena, Spark analiza — y juntos
permiten pasar de datos crudos a decisiones
útiles.*